安全可行主从博弈均衡
阶段三技术说明

可微最佳反应代理与安全强化学习加速

充电站微网数字孪生项目组

2026 年 9 月 11 日

摘要：本说明报告 SFSE 研究第三阶段成果。阶段三在阶段二（精确 MILP、BRI、安全层）基础上，引入两类加速方法：(1) **可微最佳反应代理**——用神经网络学习下层 EV 响应映射 $p \mapsto E(p)$，响应推理较 LP 加速约 425 倍；(2) **安全强化学习定价策略**——用 MILP 示范数据行为克隆预训练、再用 actor-critic 微调，学习" 场景 $\rightarrow$ 电价" 映射，策略与安全层联合部署。测试场景上，RL 策略相对 MILP 最优的净利润间隙仅 -1.24%，可行率 100%，端到端决策加速约 7 倍。

1 阶段三计划

表 1: 阶段三任务分解

任务	内容	产出
可微最佳反应代理	学习 $p \mapsto E(p)$，替代下层 LP，提供梯度	`surrogate.py`
场景定价环境	随机场景采样 + 跟随者响应 + 安全投影 + 奖励	`env.py`
安全强化学习	策略梯度学习场景 $\rightarrow$ 电价，安全层保证可行	`rl.py`
基准与加速对比	RL vs MILP: 收益/时间/可行率	`run_stage3.py`

2 组件一：可微最佳反应代理

2.1 方法

在随机电价向量上调用精确跟随者 LP 生成数据集 $\{(p^{(n)}, E^{(n)})\}$，训练 MLP 拟合 $p \mapsto E$。该代理可用于内循环加速，并提供关于电价的梯度，为端到端可微优化奠基。

2.2 结果

- 训练样本 1200 条，测试集 MAE = 8.97 kWh，相对误差 13.6%（下层响应为阈值型阶跃映射，平滑网络难以完全拟合）；
- 单次响应推理：LP 31.3 ms $\rightarrow$ 代理 0.074 ms，加速约 **425**×。

3 组件二：安全强化学习定价策略

3.1 问题设定

将运营商的场景化定价建模为单步上下文老虎机：状态为场景特征（风光、负荷、用户保留效用与容量），动作为电价向量，奖励为经安全投影后的净利润。

3.2 训练方法

采用” 示范预训练 + 策略梯度微调”：

1. 用 120 个随机场景的 **MILP 最优电价**做示范，行为克隆预训练策略均值（learning-to-optimize）；
2. 用 actor-critic（A2C）在环境中微调 400 episodes，熵正则鼓励探索；
3. 部署时策略输出电价，经跟随者响应与**安全投影层**得到严格可行调度。

3.3 结果

表 2: 测试场景对比（15 个随机场景）

方法	平均净利润	单场景耗时	可行率
MILP（精确）	433.99 元	639.9 ms	100%
安全 RL（本方法）	428.61 元	98.2 ms	100%
最优性间隙	−5.38 元（−1.24%）	加速 **7**×	—

4 阶段二与阶段三综合结果

表 3: 各方法对比（6 时段 / 3 用户小算例）

方法	净利润	时间	可行率	说明
MILP（KKT+ 大 M）	415.66 元	0.95 s	100%	精确真解
BRI 多起点	415.66 元	24.9 s	100%	间隙 0
安全层投影	—	—	100%	幂等
安全 RL（跨场景）	−1.24%	7× 加速	100%	场景化定价
代理响应推理	—	425×	—	$p \mapsto E$

5 结论与阶段四衔接

阶段三实现了两类加速：代理模型将下层响应推理加速约两个数量级；安全 RL 将” 场景 → 电价 + 调度” 的端到端决策加速约 7 倍，且净利润间隙仅 −1.24%、可行率 100%。代理的相对

误差偏高，后续可通过分用户建模、阈值附近加采样与更深的网络进一步降低。阶段四将把方法推广到**全尺寸数字孪生场景**（24 时段、光伏 3000 kW / 风电 2000 kW / 充电桩 14400 kW / 储能 3750 kW • 7500 kWh），完成基线对比（B1–B4）、消融实验与 SOH 耦合，验证方法的可扩展性与多维占优性。