强化学习求解方向专题调研

离网高速充电站—用户主从博弈调度的
强化学习求解技术

充电站微网数字孪生项目组

2026 年 9 月 10 日

摘要：本报告是“离网微网高速充电站与用户主从博弈优化调度策略”课题的第二份专题调研，聚焦**强化学习（Reinforcement Learning, RL）求解方向**。报告基于 OpenAlex/Crossref 检索的 30 余篇文献，系统梳理了 RL 与数学规划方法的对比、MDP 建模要素、单智能体与多智能体算法谱系、RL 与主从博弈的四种结合范式、约束与安全处理手段，并总结了该方向的痛点、亮点与趋势。分析表明：RL 擅长处理不确定性、实时性与高维决策，但存在约束满足无保证、样本效率低、可解释性差、均衡收敛性难证等问题；“RL + MPC/优化”混合、安全强化学习、多智能体集中训练分散执行（CTDE）、离线/联邦 RL 是当前主要突破口。报告最后给出将 RL 嵌入主从博弈框架的落地方案，建议以现有 OpenDSS 数字孪生平台封装为训练环境。

1 调研背景与范围

1.1 为什么关注强化学习求解

在离网高速充电站—用户主从博弈问题中，若采用传统数学规划路线（下层 KKT 重构 + 大 M 线性化 + MILP），可获得严格的均衡解，但面临三重挑战：

- **不确定性**：光伏/风电出力、交通流与充电需求、用户行为随机，精确概率分布难以获得；
- **计算复杂度**：双层非凸 + 互补约束 + 整数变量，规模增大后难以满足实时滚动调度；
- **信息不对称**：用户真实响应参数与成本函数属于隐私，集中式优化难以获取。

强化学习通过“与环境的交互试错”学习策略，**无需精确系统模型、可在毫秒级在线决策、天然支持分散式部署**，因此成为求解该类博弈调度问题的重要补充甚至替代方案。

1.2 调研范围

本报告覆盖以下子方向：

1. RL 与数学规划在微网/充电站调度中的定位与对比；
2. RL 的 MDP 建模（状态、动作、奖励）在充电站场景的映射；
3. 单智能体与多智能体 RL 算法谱系；
4. RL 与主从博弈（Stackelberg Game）的结合范式；
5. 约束满足、安全性、样本效率等关键问题的处理手段；
6. 面向本课题的落地建议。

1.3 文献概览

检索式包括 `deep reinforcement learning electric vehicle charging station scheduling`、`multi-agent reinforcement learning microgrid energy management`、`safe reinforcement learning power system`、`reinforcement learning Stackelberg game bilevel`、`offline reinforcement learning energy management` 等。文献时间跨度 2017—2025 年，主力集中在 2019—2024 年；主要发表期刊包括 *IEEE Transactions on Smart Grid*、*IEEE Transactions on Industrial Informatics*、*Applied Energy*、*Energy*、*Renewable and Sustainable Energy Reviews*、*Journal of Modern Power Systems and Clean Energy*、*IEEE Access* 等。

2 强化学习与数学规划方法的对比

RL 与数学规划（MPC/MILP/MPEC）并非互斥，而是互补。表 1 给出二者在关键维度上的对比。

表 1: 数学规划与强化学习方法的对比

维度	数学规划（MPC/MILP/MPEC）	强化学习（RL）
模型依赖	需精确物理/经济模型与参数	模型无关，仅需交互数据
不确定性	需显式建模（场景/鲁棒/机会约束）	隐式学习，适应随机环境
最优性	有最优性/次优性保证，可证均衡	通常无全局最优保证，收敛性依赖算法
约束满足	硬约束可严格满足	需专门设计（罚函数/安全层/动作屏蔽）
实时性	大规模问题在线求解慢	训练后可毫秒级在线推理
可解释性	强，可分析影子价格/灵敏度	弱，黑箱决策
样本效率	无需训练数据	需要大量交互或历史数据
多主体	双层/MPEC 求解困难	MARL 天然支持分散决策

实践中的主流结论是：**“优化保证约束与物理可行性，RL 提供快速、自适应的策略”**，即采用混合架构而非二选一 [7, 8]。

3 强化学习建模框架

3.1 充电站—用户博弈的 MDP 映射

将调度问题建模为马尔可夫决策过程（MDP）$\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$，其在充电站场景的典型映射见表 2。

3.2 单智能体算法谱系

主流 RL 算法按动作空间与学习目标可分为值函数法、策略梯度法与 Actor-Critic 法，见表 3。其中 SAC、TD3、PPO 是当前储能/充电调度中最常用的三种算法 [11, 14, 17]。

3.3 多智能体强化学习（MARL）

当存在多个充电站、多个微网或多个利益主体时，需采用 MARL。主流范式包括：

表 2: 充电站—用户博弈问题的 MDP 要素映射

要素	充电站/微网场景中的具体内容
状态 s_t	储能 SOC/SOH、光伏与风电出力、当前/预测电价、EV 到达率与剩余 SOC、交通流量、时间（时段/节假日）、上一时刻功率
动作 a_t	储能充放电功率、充电站售电/购电电价或服务费、充电桩功率分配、V2G 放电激励、失负荷/弃电决策
奖励 r_t	日净利润、负运营成本、用户成本/满意度、电池退化成本、失负荷/弃电惩罚、电压/功率偏差惩罚
转移 P	新能源与负荷的随机演化、EV 到达过程、用户对价格的响应行为
折扣 γ	权衡即时收益与长期收益（电池寿命、SOH）

表 3: 主流强化学习算法及其在能源调度中的适用性

算法	类型	动作空间	特点与适用场景
DQN / Double / Dueling	值函数	离散	充电桩通断、档位选择；易发散、难处理连续功率
DDPG	Actor-Critic	连续	储能连续充放电；样本效率低、易过估计
TD3	Actor-Critic	连续	DDPG 改进，双 critic 抑制过估计，稳定性好
SAC	Actor-Critic	连续	最大熵、探索强、鲁棒，适合连续功率调度
PPO	策略梯度	离散/连续	训练稳定、易调参，广泛用于微网调度

- **独立学习（IL）**：每个智能体独立用单智能体算法学习，简单但环境非平稳；
- **集中训练分散执行（CTDE）**：训练时利用全局信息，执行时仅用局部观测，代表算法有 MADDPG、COMA、QMIX、MAPPO，是当前多微网/多充电站协同的主流 [6, 20, 21]；
- **值分解**：将联合 Q 值分解为个体 Q 值之和（VDN/QMIX），适合协作型任务；
- **联邦/分布式 RL**：保护各主体数据隐私，支持跨主体协同训练 [18, 19]。

4 强化学习与主从博弈的结合范式

这是本课题最核心的问题。文献中 RL 与 Stackelberg 主从博弈的结合可归纳为四种范式（表 4）。

表 4: RL 与主从博弈的四种结合范式

范式	上层（领导者）	下层（跟随者）	特点与代表
A. RL 解下层	优化（KKT/MILP）	RL 学习用户响应	上层可证最优，下层刻画复杂用户行为；适合用户模型难建模
B. RL 解上层	RL 学习定价/调度	优化或仿真用户	实时定价、隐私友好；下层需可解析
C. 双层均 RL	RL（运营商）	RL（用户/多智能体）	端到端博弈学习，适合大规模；均衡收敛难证
D. RL-MPC 混合	MPC 保约束	RL 提供策略/初值	兼顾约束满足与实时自适应 [7]

4.1 范式 A：下层用 RL 学习用户响应

上层运营商仍用优化模型出清电价，下层 EV 用户用 RL 学习充放电策略。优点是保留了上层定价的最优性与可解释性，同时用 RL 处理用户行为的高度非线性与随机性。缺点是需要上层反复调用下层策略，训练成本高。

4.2 范式 B：上层用 RL 学习定价

运营商用 RL 直接学习动态定价或储能调度策略，用户侧用优化模型或基于响应度的解析模型。文献 [12] 提出隐私保护 DRL 方法，在多个智能充电站间实现利润最大化的动态定价与能量管理，避免共享用户隐私数据；[15] 用 RL 实现与鸭形曲线相关的动态定价与电池调度。该范式适合实时定价与隐私敏感场景。

4.3 范式 C：双层/多智能体 RL 求解博弈均衡

将领导者与跟随者分别建模为智能体，用 MARL 学习 Stackelberg 均衡。运营商智能体学习定价/调度，用户（或用户聚合）智能体学习响应，通过多轮交互逼近均衡。该方法扩展性好，但**均衡存在性、唯一性与收敛性缺乏理论保证**，且训练不稳定。

4.4 范式 D：RL-MPC 混合

用 MPC 处理硬约束与滚动优化，用 RL 学习价值函数、终端成本或策略初始化，形成“reinforced MPC”。文献 [7] 在建筑能量管理中将 RL 与 MPC 融合，结果表明纯 RL 难以满足约束，而 RL-MPC 可在保证约束的同时接近 MPC 性能并适应不确定环境。这一思路对**离网场景的硬约束（SOC、功率自平衡、失负荷）尤为重要**。

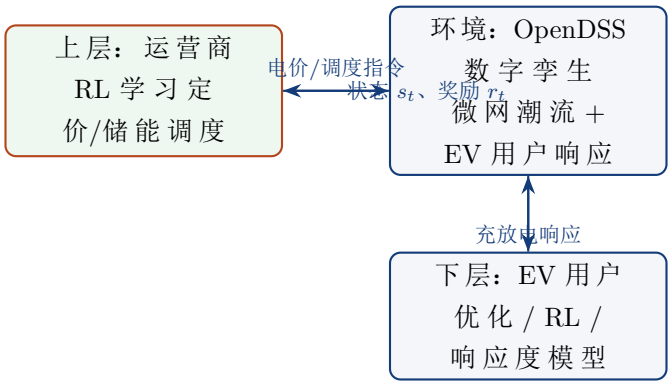


图 1： RL 与主从博弈结合的典型训练闭环（以范式 B 为例）

5 约束处理与安全强化学习

RL 的最大短板是**约束满足无保证**。在离网微网中，SOC 越限、功率不平衡、失负荷等后果严重，因此安全 RL 是必选项。主流手段包括：

- **动作屏蔽/投影**：将动作投影到可行域，保证 SOC、功率上下限等硬约束；
- **罚函数法**：将约束违反折算为负奖励，实现简单但难以严格保证；
- **拉格朗日法/约束策略优化**：将约束作为对偶变量引入，如 CPO、RCPO；
- **安全层/物理信息约束**：在策略之上叠加基于物理模型的校正层，如文献 [8] 提出“物理信息引导的安全层”，通过求解动作校正问题保证所有物理约束，文献 [9] 提出监督式多智能体安全策略学习（SMAS-PL），利用梯度信息保证配网 AC 潮流约束；
- **RL-MPC 混合**：由 MPC 兜底满足硬约束 [7]。

6 关键痛点

1. **约束满足无保证**。纯 RL 是黑箱决策，难以严格满足离网微网的 SOC、功率平衡与电压约束；安全 RL 的保守性与经济性难以兼顾 [8, 9]。
2. **样本效率低、训练成本高**。深度 RL 通常需要海量交互，真实微网无法承受在线试错；仿真到现实（sim-to-real）差距显著。
3. **均衡收敛性无理论保证**。多智能体博弈学习中，环境非平稳、策略相互影响，Stackelberg 均衡的存在性、唯一性与收敛性难以证明 [6]。

4. **奖励设计与多目标权衡困难。**净利润、电池寿命、用户满意度、可靠性等多目标需折算为单一奖励，权重敏感且难以标定。
5. **可解释性差。**调度人员难以理解与信任 RL 决策，监管与责任界定困难。
6. **泛化能力不足。**场景/拓扑/参数变化后策略需重新训练，跨场景迁移困难。
7. **数据隐私与多主体信息壁垒。**多主体协同需要共享状态，与用户隐私、商业机密冲突，需联邦学习等手段 [12, 18]。
8. **缺乏标准环境与评测基准。**与建筑领域 BOPTEST 相比，充电站/微网 RL 缺少统一仿真环境与基准，结果难复现、难横向比较 [7]。
9. **电池退化建模与 RL 耦合不足。**退化成本多为简化线性项，SOH 状态维度高、稀疏，难以被 RL 有效学习。

7 亮点与创新趋势

1. **“RL + 优化/MPC”混合架构成为主流。**用优化保约束、RL 保自适应，兼顾可靠性与实时性 [7, 8]。
2. **安全强化学习快速兴起。**物理信息安全层、约束策略优化、动作校正等，使 RL 可用于有硬约束的电力系统 [8, 9]。
3. **多智能体 CTDE 框架广泛应用。**集中训练分散执行，兼顾协同性能与隐私/可扩展性，适合多充电站、多微网协同 [6, 20, 21]。
4. **图神经网络/注意力机制与 RL 结合。**用于处理拓扑结构、变规模智能体与交通—电力耦合关系。
5. **离线 RL 与迁移学习。**利用历史数据离线训练，降低在线试错风险；元学习/迁移学习提升跨场景泛化。
6. **联邦强化学习保护隐私。**多主体在不共享原始数据的前提下协同训练 [18, 19]。
7. **与博弈论深度融合。**用 MARL 求解 Stackelberg/Nash 均衡，形成“学习型博弈”，处理用户有限理性与信息不对称 [13, 22]。
8. **面向高速场景的专门研究出现。**如文献 [2] 针对高速公路 EV 充电站自消纳调度提出多智能体 DRL 方法，与本课题高度相关。
9. **数字孪生作为训练环境。**用高保真仿真（如 OpenDSS）提供安全、可控的 RL 训练与验证平台，加速 sim-to-real 迁移。

8 对本课题的落地建议

8.1 推荐架构：RL 与优化分工的混合主从博弈

结合离网高速充电站的硬约束特性与用户行为复杂性，建议采用**“上层优化定价 + 下层 RL 用户响应 + 安全层兜底”**的混合架构：

- **上层（运营商/领导者）**：用 MILP/MPC 求解储能调度与电价，保证功率自平衡、SOC、终端能量等硬约束，并可输出可解释的影子价格；
- **下层（EV 用户/跟随者）**：用 SAC/TD3 或 CTDE-MARL 学习用户充放电与 V2G 响应，刻画有限理性与随机行为；
- **安全层**：在 RL 动作输出后叠加动作投影/校正，确保 SOC 与功率约束；对离网缺额与失负荷设置硬性惩罚；
- **训练环境**：将现有 OpenDSS 数字孪生模型封装为 Gym/Gymnasium 环境，状态含 SOC/SOH、风光预测、交通流与电价，奖励为日净利润减去退化与惩罚。

8.2 实施步骤

1. **基线搭建**：以现有规则策略与 MPC 策略作为 baseline，建立统一评测指标（日净利润、失负荷率、弃电率、EV 满足率、SOH 衰减）；
2. **环境封装**：将 OpenDSS 逐时步仿真封装为 RL 环境，定义状态/动作/奖励；
3. **单智能体验证**：先用 SAC/PPO 学习储能调度，验证 RL 在离网约束下的可行性与收益；
4. **多智能体扩展**：引入用户/多充电站智能体，采用 CTDE（MAPPO/QMIX）求解博弈；
5. **安全增强**：加入安全层或 RL-MPC 混合，消除约束违反；
6. **对比分析**：RL vs MPC vs 混合架构，在确定性/随机/极端场景下对比经济性、可靠性与鲁棒性。

8.3 预期贡献

- 提出面向**离网**高速充电站的 RL—主从博弈混合调度框架，弥补纯 RL 约束不可控的缺陷；
- 用**安全强化学习**保证离网功率自平衡与 SOC 约束，提升工程可用性；
- 以**数字孪生**为训练与验证环境，形成可复现的评测基准。

参考文献

参考文献

[1] An introduction to deep reinforcement learning[J]. Foundations and Trends in Machine Learning, 2018, 11(3-4): 219–354. DOI:10.1561/2200000071.

[2] Optimal self-consumption scheduling of highway electric vehicle charging station based on multi-agent deep reinforcement learning[J]. Renewable Energy, 2024, 237: 121982. DOI:10.1016/j.renene.2024.121982.

[3] Cooperative management for PV/ESS-enabled electric vehicle charging stations: A multiagent deep reinforcement learning approach[J]. IEEE Transactions on Industrial Informatics, 2019, 16(5): 3493–3503. DOI:10.1109/TII.2019.2944183.

[4] Multi-agent deep reinforcement learning approach for EV charging scheduling in a smart grid[J]. Applied Energy, 2022, 328: 120111. DOI:10.1016/j.apenergy.2022.120111.

[5] Effective charging planning based on deep reinforcement learning for electric vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(1): 542–554. DOI:10.1109/TITS.2020.3002271.

[6] Multistep multiagent reinforcement learning for optimal energy schedule strategy of charging stations in smart grid[J]. IEEE Transactions on Cybernetics, 2022, 53(7): 4292–4305. DOI:10.1109/TCYB.2022.3165074.

[7] Reinforced model predictive control (RL-MPC) for building energy management[J]. Applied Energy, 2022, 309: 118346. DOI:10.1016/j.apenergy.2021.118346.

[8] Secure energy management of multi-energy microgrid: A physical-informed safe reinforcement learning approach[J]. Applied Energy, 2023, 335: 120759. DOI:10.1016/j.apenergy.2023.120759.

[9] Multi-agent safe policy learning for power management of networked microgrids[J]. IEEE Transactions on Smart Grid, 2020, 12(2): 1048–1062. DOI:10.1109/TSG.2020.3034827.

[10] Decentralized multi-agent based energy management of microgrid using reinforcement learning[J]. International Journal of Electrical Power & Energy Systems, 2020, 122: 106211. DOI:10.1016/j.ijepes.2020.106211.

[11] Deep reinforcement learning for energy management in a microgrid with flexible demand[J]. Sustainable Energy, Grids and Networks, 2020, 24: 100413. DOI:10.1016/j.segan.2020.100413.

[12] Dynamic pricing and energy management for profit maximization in multiple smart electric vehicle charging stations: A privacy-preserving deep reinforcement learning approach[J]. Applied Energy, 2021, 304: 117754. DOI:10.1016/j.apenergy.2021.117754.

[13] Application of game theory in integrated energy system: A review[J]. IEEE Access, 2020, 8: 93380–93396. DOI:10.1109/ACCESS.2020.2994133.

[14] A soft actor-critic reinforcement learning framework for optimal energy management in electric vehicles with hybrid storage[J]. Journal of Energy Storage, 2024, 98: 113344. DOI:10.1016/j.est.2024.113344.

[15] Duck curve aware dynamic pricing and battery scheduling strategy using reinforcement learning[J]. IEEE Transactions on Smart Grid, 2023, 15(1): 457–469. DOI:10.1109/TSG.2023.3288355.

[16] Optimal electric vehicle charging strategy with Markov decision process and reinforcement learning technique[J]. IEEE Transactions on Industry Applications, 2020, 56(5): 5811–5823. DOI:10.1109/TIA.2020.2990096.

[17] Electric vehicle charging management based on deep reinforcement learning[J]. Journal of Modern Power Systems and Clean Energy, 2022, 10(3): 719–730. DOI:10.35833/MPCE.2020.000460.

[18] A multiagent federated reinforcement learning approach for plug-in electric vehicle fleet charging coordination in a residential community[J]. IEEE Access, 2022, 10: 98535–98548. DOI:10.1109/ACCESS.2022.3206020.

[19] A multi-agent reinforcement learning-based data-driven method for home energy management[J]. IEEE Transactions on Smart Grid, 2020, 11(4): 3201–3211. DOI:10.1109/TSG.2020.2971427.

[20] Multi-agent deep reinforcement learning based distributed control architecture for interconnected multi-energy microgrid energy management and optimization[J]. Energy Conversion and Management, 2023, 277: 116647. DOI:10.1016/j.enconman.2022.116647.

[21] Multi-energy management of interconnected multi-microgrid system using multi-agent deep reinforcement learning[J]. Journal of Modern Power Systems and Clean Energy, 2023, 11(6): 1811–1821. DOI:10.35833/MPCE.2022.000473.

[22] An optimized decision model for electric vehicle aggregator participation in the electricity market based on the Stackelberg game[J]. Sustainability, 2023, 15(20): 15127. DOI:10.3390/su152015127.

[23] Reinforcement learning and its applications in modern power and energy systems: A review[J]. Journal of Modern Power Systems and Clean Energy, 2020, 8(6): 1029–1042. DOI:10.35833/MPCE.2020.000552.

[24] Applications of reinforcement learning in energy systems[J]. Renewable and Sustainable Energy Reviews, 2020, 137: 110618. DOI:10.1016/j.rser.2020.110618.

[25] Optimal priority rule-enhanced deep reinforcement learning for charging scheduling in an electric vehicle battery swapping station[J]. IEEE Transactions on Smart Grid, 2023, 14(5): 4011–4021. DOI:10.1109/TSG.2023.3250505.

[26] Fuzzy Q-learning for multi-agent decentralized energy management in microgrids[J]. Applied Energy, 2018, 219: 53–67. DOI:10.1016/j.apenergy.2018.03.017.

[27] Virtual power plant containing electric vehicles scheduling strategies based on deep reinforcement learning[J]. Electric Power Systems Research, 2021, 201: 107714. DOI:10.1016/j.epsr.2021.107714.

[28] Multi-agent deep reinforcement learning for distributed energy management and strategy optimization of microgrid market[J]. Sustainable Cities and Society, 2021, 74: 103163. DOI:10.1016/j.scs.2021.103163.

[29] Building energy management with reinforcement learning and model predictive control: A survey[J]. IEEE Access, 2022, 10: 23592–23607. DOI:10.1109/ACCESS.2022.3156581.

[30] A discount-based time-of-use electricity pricing strategy for demand response with minimum information using reinforcement learning[J]. IEEE Access, 2022, 10: 49889–49902. DOI:10.1109/ACCESS.2022.3175839.